



SOLUCIÓN MULTIAGENTE PARA ANÁLISIS AEROESPACIAL EN LATAM

UNIVERSIDAD POPULAR
DEL CESAR
Seccional Aguachica

Informe Técnico — Etapa 1: Construcción de la Base de Conocimiento Vectorial

RONALD ANDRÉS NIETO COLLANTE
YEISON FERNANDO BOLIVAR PARDO
DAVID LEONARDO SANCHEZ GUERRA
MARIO ESTEBAN GUERRA TUIRAN

CODEFEST AD ASTRA 2026
EQUIPO SIIU

UNIVERSIDAD POPULAR DEL CESAR
SECCIONAL AGUACHICA

13 DE AGOSTO DE 2026

1. Introducción y contexto del reto

El CODEFEST AD ASTRA 2026 es un espacio académico y tecnológico dedicado a la innovación en el dominio aeroespacial y de defensa. En esta edición se propuso el diseño de una arquitectura inteligente de tipo multiagente, capaz de analizar fenómenos estratégicos con incidencia directa en el ámbito aéreo y espacial a partir de fuentes de información abiertas. El presente informe documenta el trabajo desarrollado por el equipo SIU, de la Universidad Popular del Cesar, Seccional Aguachica, durante la primera etapa del reto.

El análisis propuesto se aborda desde tres niveles complementarios. En el plano global, el interés se concentra en identificar tendencias emergentes vinculadas a la tecnología espacial, el cambio climático, la innovación y los riesgos de alcance mundial. En el plano regional, el foco se traslada a las dinámicas propias de América Latina y el Caribe, con particular atención a los factores sociales, políticos, económicos y ambientales que las caracterizan. Finalmente, en el plano nacional, la información proviene de observatorios académicos e institucionales colombianos, lo que permite situar los fenómenos globales y regionales dentro de un contexto local concreto.

Sobre esa base, se definieron tres fenómenos de análisis considerados críticos para la seguridad y el desarrollo estratégico de la región. El primero corresponde al uso de la inteligencia artificial en entornos militares, entendido como el examen de su desarrollo, aplicación e impacto en la Defensa Nacional, junto con las oportunidades, brechas y riesgos que conlleva. El segundo aborda la seguridad espacial y la congestión de la órbita baja terrestre (LEO), en particular los riesgos derivados de la proliferación de desechos espaciales. El tercero se ocupa de las dinámicas territoriales en América Latina, entendidas como el conjunto de variables sociales, políticas, económicas y ambientales con implicaciones estratégicas para la región. Este enfoque integral exige que los equipos participantes sean capaces de organizar, procesar y recuperar información de manera eficiente, transformando grandes volúmenes de datos heterogéneos en conocimiento estratégico aprovechable.

El objetivo específico de esta primera etapa consistió en construir una base de conocimiento vectorial a partir de las fuentes documentales suministradas por el comité organizador. Dicha base constituye la infraestructura inicial de recuperación de información sobre la cual se integrará, en la segunda etapa —de carácter presencial—, un asistente conversacional multiagente. La evaluación de esta fase se concentra exclusivamente en la calidad de recuperación de la base construida, es decir, en la pertinencia y relevancia de los documentos y fragmentos que el sistema retorna ante consultas formuladas en lenguaje natural. El propósito de fondo es asegurar que la solución propuesta no sea únicamente sólida desde el punto de vista técnico, sino también aplicable y estratégica en escenarios reales de análisis aeroespacial.

2. Metodología para la construcción de la base de conocimiento vectorial

La construcción de la base de conocimiento vectorial partió de una etapa de fragmentación del texto, conocida como chunking, mediante la cual los documentos originales se dividieron en unidades más pequeñas —los chunks— que posteriormente fueron codificadas como vectores y almacenadas en un índice FAISS junto con su metadata. Esta fragmentación resulta indispensable por dos razones: por un lado, los modelos de codificación tienen un límite en la cantidad de tokens que pueden procesar simultáneamente; por otro, los documentos completos suelen contener múltiples ideas heterogéneas que no pueden representarse adecuadamente en un único vector. Un fragmento bien delimitado, en cambio, permite capturar con precisión el significado semántico de una idea o de un argumento cohesivo.

El corpus se segmentó principalmente por párrafos, respetando los límites naturales del texto y garantizando la completitud lingüística de cada unidad. En los casos en que un párrafo superaba el límite máximo de tokens admitido por el encoder, se aplicó un ajuste retrocediendo hasta el final de la última oración completa que cupiera dentro del rango permitido, evitando así cortes abruptos que alteraran el sentido del texto. El tamaño de los fragmentos se fijó en un rango de entre 500 y 1.000 tokens, con el propósito de que cada chunk conservara suficiente contexto semántico sin superar las restricciones técnicas del modelo de codificación empleado.

Este rango no se eligió de manera arbitraria, sino en función de las exigencias propias de las consultas estratégicas en el ámbito aeroespacial. Los fragmentos demasiado extensos tienden a mezclar varias ideas en un mismo vector, lo que dificulta la precisión de la recuperación; los fragmentos demasiado breves, en cambio, pierden contexto y reducen la relevancia semántica de la búsqueda. El intervalo de 500 a 1.000 tokens ofrece un equilibrio adecuado entre la coherencia temática de cada unidad y la eficiencia del proceso de indexación y búsqueda, permitiendo que la base vectorial responda con mayor precisión a consultas relacionadas con inteligencia artificial en defensa, seguridad espacial en órbita baja y dinámicas territoriales en América Latina.

A modo de ilustración, un texto como el siguiente —referido a la proliferación de objetos espaciales no funcionales— se fragmentó respetando la unidad de sentido de cada oración:

Este ejemplo muestra cómo un pasaje extenso puede dividirse en unidades más pequeñas sin perder coherencia temática, facilitando su posterior indexación en FAISS.

La calidad de la base vectorial depende, en igual medida, del modelo de codificación empleado para generar los embeddings. Para este proyecto se seleccionó un encoder de la familia BERT, específicamente un modelo de la biblioteca sentence-transformers, disponible de forma pública en HuggingFace bajo licencia Apache 2.0. La elección respondió a cuatro criterios. En primer lugar, la precisión semántica: el modelo genera representaciones que capturan con exactitud el significado de los fragmentos, condición esencial para resolver consultas estratégicas en el dominio aeroespacial. En segundo lugar, el soporte multilingüe: dado que el corpus incluye documentos en español, inglés y portugués, se priorizó un modelo capaz de operar de forma nativa en los tres idiomas, garantizando la comparabilidad entre representaciones. En tercer lugar, la eficiencia computacional, entendida como tiempos de inferencia razonables y un consumo de memoria compatible con los recursos disponibles, lo que permitió indexar un volumen considerable de fragmentos sin comprometer el rendimiento del sistema. Por último, la licencia abierta del modelo aseguró su uso legítimo dentro del marco del reto.

En esta etapa se trabajó con un único encoder, decisión orientada a mantener la consistencia de la representación semántica a lo largo de todo el corpus. No obstante, se reconoce que el uso combinado de varios encoders podría resultar ventajoso en desarrollos futuros —por ejemplo, complementando un modelo multilingüe con otro especializado en textos técnicos, equilibrando precisión y eficiencia mediante índices FAISS complementarios, o mejorando la robustez de la recuperación al fusionar los resultados provenientes de distintos espacios vectoriales.

La gestión de la base vectorial se realizó mediante FAISS (Facebook AI Similarity Search), biblioteca de uso obligatorio en el reto por su capacidad de indexar millones de vectores y ejecutar búsquedas de similitud en tiempos del orden de milisegundos. El tipo de índice seleccionado fue IndexFlatIP, equivalente a la similitud coseno cuando los vectores se encuentran normalizados. Esta elección garantiza resultados exactos —sin aproximaciones— y resulta adecuada para el volumen de documentos manejado en esta primera etapa. Su idoneidad se sustenta en tres factores: la rapidez de búsqueda, que permite obtener resultados en milisegundos incluso con miles de fragmentos indexados; el uso eficiente de memoria, al no requerir estructuras auxiliares adicionales; y la escalabilidad suficiente para el tamaño actual del corpus, aunque se reconoce que índices aproximados como IVF o HNSW ofrecerían ventajas en escenarios de mayor volumen documental.

La construcción y persistencia del índice se desarrolló en tres pasos consecutivos. Primero, cada fragmento del corpus fue codificado mediante el encoder seleccionado, produciendo un vector semántico normalizado. Segundo, los vectores se incorporaron al índice a través de la función `faiss.IndexFlatIP()`, que asigna un identificador interno a cada uno. Tercero, el

índice se guardó en disco mediante `faiss.write_index()` y su correcta carga se verificó posteriormente con `faiss.read_index()`, lo que asegura la reproducibilidad y la portabilidad del sistema en distintos entornos de ejecución.

3. Generación de resultados y reproducibilidad

Uno de los entregables obligatorios de la Etapa 1 es el archivo `resultados.jsonl`, que almacena en formato JSON Lines las respuestas generadas por el sistema ante el conjunto de consultas de evaluación. Este archivo se produjo mediante la ejecución del script `generador.py`, cuyo funcionamiento puede describirse como una secuencia de cuatro pasos. En primer lugar, el script carga el índice FAISS previamente construido a través de `faiss.read_index()`, operación que garantiza la disponibilidad de los vectores normalizados y sus identificadores internos. En segundo lugar, procesa el archivo de consultas suministrado por el comité organizador —correspondiente a las cincuenta preguntas identificadas como `q001` a `q050`— y transforma cada una en un vector de entrada mediante el mismo encoder utilizado durante la indexación. En tercer lugar, compara ese vector de consulta contra los vectores almacenados en FAISS; el índice devuelve los *k* fragmentos más similares junto con sus puntuaciones, y a partir de los identificadores internos se recupera la metadata correspondiente —`doc_id`, `chunk_id`, texto, fenómeno, entre otros campos—. Finalmente, el script construye un objeto JSON por cada consulta, que incluye los tres documentos más relevantes a nivel de `doc_id` y los diez fragmentos más relevantes a nivel de `chunk_id`, y escribe cada objeto como una línea independiente del archivo, cumpliendo con el formato JSON Lines exigido por el reto.

El archivo resultante contiene exactamente cincuenta líneas, una por cada consulta evaluada, sin separadores adicionales más allá del salto de línea entre registros. A continuación se presenta un ejemplo simplificado de la estructura de una de estas líneas:

```

{
  "query_id": "q001",
  "documents": [
    {"rank": 1, "doc_id": "DOC-042"},
    {"rank": 2, "doc_id": "DOC-017"},
    {"rank": 3, "doc_id": "DOC-091"}
  ],
  "fragments": [
    {
      "rank": 1,
      "chunk_id": "DOC-042-chunk-007", "doc_id": "DOC-042",
      "text": "La proliferacion de objetos espaciales artificiales no funcionales..."
    },
    {
      "rank": 2,
      "chunk_id": "DOC-017-chunk-003", "doc_id": "DOC-017",
      "text": "El uso de inteligencia artificial en defensa nacional plantea..."
    }
  ]
}

```

Este formato asegura la trazabilidad de cada resultado, vinculando los fragmentos recuperados con sus documentos de origen y permitiendo que la evaluación se realice tanto a nivel de fragmento como de documento completo.

El diseño del script generador.py busca, además, garantizar que el proceso sea reproducible y verificable por cualquier equipo evaluador: que, al ejecutarse en un entorno compatible, arroje un archivo idéntico al entregado. Esta propiedad se sostiene en cuatro decisiones de diseño: el uso consistente del mismo encoder para todas las consultas, la normalización de los vectores antes de la indexación, la persistencia del índice mediante `faiss.write_index()` y su recuperación mediante `faiss.read_index()`, y la generación de resultados siguiendo estrictamente el esquema definido por el reto. En conjunto, estas decisiones aseguran que cualquier equipo que ejecute el script sobre el mismo corpus obtenga exactamente los mismos resultados, cumpliendo así con el principio de reproducibilidad exigido en esta etapa.

4. Grafo de conocimiento como componente complementario

Como complemento de la base vectorial, se implementó un grafo de conocimiento orientado a representar de manera explícita las relaciones entre las entidades relevantes del corpus, enriqueciendo así el análisis estratégico en el dominio aeroespacial. Su construcción se desarrolló en tres etapas sucesivas. La primera consistió en el reconocimiento de entidades (NER), mediante el cual se identificaron personas, organizaciones, países, tecnologías y eventos mencionados en los documentos, empleando modelos multilingües disponibles en HuggingFace. La segunda correspondió a la extracción de relaciones (RE), en la que se determinaron los vínculos semánticos entre pares de entidades dentro de cada fragmento, combinando heurísticas lingüísticas con modelos de clasificación de relaciones. La tercera etapa consistió en la integración de las tripletas resultantes —entidad, relación, entidad en una estructura de grafo construida con NetworkX en Python, la cual se exportó en formato GraphML para asegurar su compatibilidad con herramientas como Neo4j y RDFLib. El archivo resultante se entrega en la carpeta grafo/, bajo el nombre grafo.graphml.

El aporte de este componente al análisis aeroespacial es de naturaleza complementaria a la base vectorial: permite visualizar relaciones entre actores clave, fenómenos y territorios; facilita consultas semánticas de mayor complejidad, como identificar qué organizaciones colaboran con Colombia en materia de seguridad espacial; enriquece el contexto de recuperación al vincular entidades con los fragmentos que les son relevantes; y apoya el análisis prospectivo al mostrar cómo los fenómenos de alcance global se conectan con las dinámicas regionales y nacionales. En el ámbito específico de este reto, el grafo permite examinar con mayor precisión las interacciones entre países, agencias espaciales, observatorios académicos y fenómenos como la proliferación de desechos orbitales o la adopción de inteligencia artificial en la defensa.

5. Conclusiones, limitaciones y perspectivas para la Etapa 2

La solución desarrollada aporta un valor estratégico relevante al reto CODEFEST AD ASTRA 2026. La construcción de una base de conocimiento vectorial, complementada con un grafo de conocimiento, permite una recuperación precisa de información ante consultas formuladas en lenguaje natural; una integración multilingüe que hace posible consultar de manera uniforme documentos en español, inglés y portugués; un análisis enriquecido gracias a la representación explícita de relaciones entre actores, fenómenos y territorios; y una reproducibilidad garantizada por el script `generador.py`, capaz de replicar los resultados en cualquier entorno compatible.

No obstante estos avances, la solución presenta limitaciones que conviene reconocer con claridad. El uso de un índice plano (IndexFlatIP) garantiza exactitud, pero podría resultar menos eficiente frente a corpus de mayor escala. La dependencia de un único encoder restringe, por ahora, la diversidad de representaciones semánticas disponibles. La cobertura temática se limita a los documentos suministrados por el comité organizador, sin integración de fuentes externas adicionales. Y el procesamiento de relaciones dentro del grafo de conocimiento se apoyó en técnicas estándar de reconocimiento y extracción, sin recurrir todavía a modelos avanzados de extracción semántica.

De cara a la segunda etapa del reto, el equipo se propone avanzar en varias líneas de mejora. En primer lugar, la optimización de la arquitectura multiagente, integrando agentes especializados en ingesta, indexación, recuperación, análisis y evaluación, con el fin de mejorar la modularidad y la escalabilidad del sistema. En segundo lugar, la incorporación de nuevas fuentes documentales, provenientes de observatorios internacionales, agencias espaciales y centros de investigación. En tercer lugar, el enriquecimiento del grafo de conocimiento mediante relaciones más complejas y visualizaciones interactivas. En cuarto lugar, el uso combinado de varios encoders, con el propósito de mejorar la robustez y la precisión de la recuperación. Y, finalmente, la optimización del rendimiento del sistema mediante la exploración de índices aproximados como IVF o HNSW, orientados a reducir los tiempos de respuesta en corpus de mayor tamaño.